

Documentación de Desarrollo


PLN2 - Práctica 1: Clasificación de Géneros Musicales

Autor: Carmen Maeso

Daniel del Nuevo

Diego

Curso: 2025-26



Universidad Rey Juan Carlos
25 de noviembre de 2025

Índice

1. Introducción	2
1.1. Objetivos	2
2. Arquitectura del Sistema	2
2.1. Estructura de Directorios	2
3. Metodología	2
3.1. Selección y Preprocesamiento de Datos	2
3.2. Vectorización y Representación	3
3.3. Modelo de Clasificación	3
4. Experimentación y Resultados	3
4.1. Métricas de Evaluación	3
4.2. Análisis por Clase	3
4.3. Explicabilidad	4
5. Conclusiones	4
5.1. Trabajo Futuro	4

1. Introducción

Este documento sirve como memoria técnica y documentación de desarrollo para la Práctica 1 de la asignatura Procesamiento del Lenguaje Natural 2 (PLN2).

1.1. Objetivos

El objetivo principal de este proyecto es desarrollar un sistema de Procesamiento del Lenguaje Natural (PLN) capaz de clasificar canciones en sus respectivos géneros musicales basándose únicamente en la letra (lyrics) de las mismas. Se busca implementar un pipeline completo que incluya la adquisición y limpieza de datos, el entrenamiento de modelos de clasificación (baselines y avanzados), y un análisis exhaustivo de los errores y la explicabilidad de las predicciones.

2. Arquitectura del Sistema

El proyecto está estructurado de manera modular en el directorio `src/` para facilitar el mantenimiento, la reproducibilidad y la escalabilidad.

2.1. Estructura de Directorios

- `src/data`: Contiene la lógica para la gestión de datos.
 - **DatasetManager**: Encargado de la descarga y carga de los datasets desde fuentes externas (Mendeley, Kaggle/HuggingFace).
 - **DataProcessor**: Realiza la limpieza, normalización de etiquetas, deduplicación y balanceo de clases.
- `src/models`: Implementación de los modelos de clasificación.
 - **BaselineTrainer**: Clase para el entrenamiento de modelos lineales (Regresión Logística mediante SGD) utilizando representaciones TF-IDF. Gestiona la partición de datos y el entrenamiento iterativo.
- `src/analysis`: Herramientas para la evaluación y explicabilidad.
 - **ErrorAnalyzer**: Genera matrices de confusión, extrae ejemplos mal clasificados, proporciona explicabilidad basada en coeficientes lineales (feature importance) y realiza análisis de rendimiento por subgrupos (ej. longitud del texto).
- `src/utils`: Funciones de utilidad para entrada/salida y configuración del proyecto.

3. Metodología

El desarrollo del proyecto ha seguido un flujo de trabajo iterativo, comenzando por la preparación de los datos y estableciendo un baseline sólido antes de proceder a análisis más profundos.

3.1. Selección y Preprocesamiento de Datos

Se han utilizado datasets de letras de canciones obtenidos de fuentes públicas. El proceso de curación de datos incluyó:

1. **Filtrado**: Se seleccionaron únicamente canciones en idioma inglés (`lang='en'`).
2. **Unificación**: Se estandarizó el esquema de los datos a dos columnas principales: `text` y `label`.

3. **Limpieza:** Eliminación de duplicados para evitar fugas de información entre conjuntos de entrenamiento y prueba.
4. **Balanceo:** Se aplicó submuestreo (undersampling) para equilibrar las clases, resultando en aproximadamente 85,000 ejemplos por género.

3.2. Vectorización y Representación

Para el modelo baseline, se utilizó la técnica **TF-IDF** (Term Frequency-Inverse Document Frequency) con las siguientes configuraciones:

- **Vocabulario:** Limitado a las 20,000 características más importantes (`max_features=20000`) para controlar la dimensionalidad.
- **N-gramas:** Se incluyeron unigramas y bigramas (`ngram_range=(1, 2)`) para capturar contexto local.
- **Stop words:** Se eliminaron palabras vacías en inglés.
- **Sublinear TF:** Se aplicó escalado logarítmico a la frecuencia de términos para reducir el impacto de palabras muy repetitivas (comunes en estribillos).

3.3. Modelo de Clasificación

Se implementó un modelo lineal utilizando **Descenso de Gradiente Estocástico (SGD)** optimizando la función de pérdida `log_loss`, lo que equivale a una **Regresión Logística**.

- **Entrenamiento:** Iterativo por épocas (10 épocas) para monitorizar la convergencia.
- **Partición:** División estratificada en Train (70 %), Validación (15 %) y Test (15 %).

4. Experimentación y Resultados

Los experimentos se realizaron utilizando el pipeline descrito, evaluando el rendimiento en el conjunto de prueba reservado.

4.1. Métricas de Evaluación

El modelo baseline alcanzó los siguientes resultados globales en el conjunto de test:

- **Accuracy:** $\approx 59\%$
- **F1-Score (Macro):** $\approx 0,58$

4.2. Análisis por Clase

El análisis detallado muestra un rendimiento desigual entre géneros:

- **Mejor desempeño:** El género **Rap** obtuvo el F1-score más alto (0,77), probablemente debido a un vocabulario distintivo y único.
- **Peor desempeño:** El género **Pop** presentó el rendimiento más bajo ($F1 \approx 0,25$), confundiendo frecuentemente con otros géneros como Rock o R&B, lo cual es consistente con la naturaleza genérica y comercial de las letras pop.

4.3. Explicabilidad

Mediante el análisis de los coeficientes del modelo lineal, se identificaron las palabras clave que más contribuyen a cada predicción. Esto permite validar que el modelo está aprendiendo características semánticas relevantes y no solo ruido. Además, se analizó el impacto de la longitud del texto en la precisión del modelo.

5. Conclusiones

El sistema desarrollado establece un punto de partida sólido para la clasificación de géneros musicales.

- Los modelos lineales basados en TF-IDF son eficientes y ofrecen una buena explicabilidad, pero tienen limitaciones para capturar matices semánticos complejos, especialmente en géneros con letras similares (Pop, Rock).
- La calidad y el balanceo de los datos han sido críticos para evitar sesgos hacia géneros mayoritarios.

5.1. Trabajo Futuro

Para mejorar el rendimiento, se propone:

- Implementar modelos basados en **Transformers** (como BERT o RoBERTa) para capturar mejor el contexto y la semántica profunda de las letras.
- Explorar técnicas de **Data Augmentation** para las clases con mayor confusión.
- Refinar el preprocesamiento para manejar mejor la jerga específica y las variaciones lingüísticas en géneros como el Rap.